PHỤ LỤC

1.Giới thiệu 2
1.1. Bối cảnh 2
1.2. Mục tiêu 2
1.3. Ý nghĩa thực tiễn 2
1.4. Thông tin về dữ liệu cần phân tích 2
1.5. Công cụ phân tích 3
2. Phương pháp: 3
2.1. Cơ sở lý thuyết các phương pháp dự báo 3
2.1.1. Mô hình Vector Autoregression 3
2.1.2. Mô hình ARIMA 5
2.1.3. Mô hình hồi quy với biến trễ Distributed Lag Models 6
2.1.4. Mô hình hồi quy Ridge 8
2.2. Các tiêu chuẩn đánh giá chất lượng dự báo 10
3. Số liệu & Thống kê mô tả 11
4. Kết quả & Phân tích: Kết quả dự báo là giá trị CPI chứ không phải là dạng chuyển đổi logarithm hay sai phân. 19
4.1. Kết quả dự báo CPI năm 2023 theo từng mô hình 19
4.2. Đánh giá độ chính xác của mô hình dự báo 21
5. Kết luận 22
6. Phụ lục 22

1.Giới thiệu

1.1. Bối cảnh

Chỉ số giá tiêu dùng (CPI) là một chỉ số kinh tế vĩ mô quan trọng phản ánh mức giá trung bình của hàng hóa và dịch vụ tiêu dùng theo thời gian. Việc theo dõi và dự báo CPI giúp Nhà nước, doanh nghiệp và người dân đưa ra các quyết định kinh tế phù hợp, nhất là trong bối cảnh biến động kinh tế toàn cầu và rủi ro lạm phát gia tăng.

1.2. Mục tiêu

Mục tiêu của báo cáo này là xây dựng mô hình dự báo chỉ số giá tiêu dùng (CPI) của Việt Nam trong năm 2023, dựa trên dữ liệu lịch sử từ tháng 01 năm 2000 đến tháng 12 năm 2022. Từ đó, giúp nhận diện xu hướng giá cả trong tương lai gần và cung cấp thông tin hỗ trợ hoạch định chính sách.

1.3. Ý nghĩa thực tiễn

Kết quả dự báo CPI năm 2023 sẽ góp phần:

- Hỗ trợ các cơ quan quản lý Nhà nước trong điều hành chính sách tiền tệ và tài khóa.
- Cung cấp thông tin cho doanh nghiệp trong việc xây dựng kế hoạch sản xuất – kinh doanh.
- Giúp người tiêu dùng và nhà đầu tư dự báo được xu hướng giá cả để có chiến lược tiêu dùng và đầu tư hợp lý.

1.4. Thông tin về dữ liệu cần phân tích

Dữ liệu được sử dụng trong bài báo cáo là một bộ dữ liệu chuỗi thời gian, được báo cáo tại ngày 15 hằng tháng, bao gồm các biến kinh tế vĩ mô trong nước và quốc tế, cùng với chỉ số giá tiêu dùng (CPI) tại Việt Nam. Tập dữ liệu bao phủ giai đoạn từ tháng 1 năm 2000 đến hết tháng 12 năm 2023, với tổng cộng hơn 288 quan sát.

Dữ liệu thể hiện CPI là biến phụ thuộc chính, được xem xét dưới dạng tổng thể và theo từng nhóm hàng hóa, dịch vụ tiêu dùng. Các biến độc lập bao gồm:

- **Biến quốc tế:** CPI của Hoa Kỳ (cpius), giá dầu thô thế giới (oilpr), lãi suất liên bang Mỹ (fedfunds), tỷ giá hối đoái thực (lreer) và danh nghĩa (lneer).
- **Biến trong nước:** Tỷ giá VND/USD (vndusd), lãi suất trái phiếu chính phủ trung/dài hạn (igrea), lãi suất liên ngân hàng kỳ hạn 1, 3, 6 tháng và qua đêm (rate1m, rate3m, rate6m, rateovn).
- **CPI nhóm hàng hóa:** Bao gồm các nhóm như thực phẩm (food), nhà ở và điện nước (hous), y tế (helth), giáo dục (educ), giao thông (tran), văn hóa - du lịch (recr), và các nhóm chi tiêu khác.

Ngoài ra, bộ dữ liệu cũng bao gồm cột cpi_2023 – thể hiện chỉ số giá tiêu dùng thực tế của năm 2023 – được dùng để đối chứng và đánh giá hiệu quả của các mô hình dự báo.

1.5. Công cụ phân tích

Các công cụ và phần mềm được sử dụng bao gồm:

- **Python**: sử dụng các thư viện như pandas, statsmodels, matplotlib, seaborn,... để xử lý dữ liệu, xây dựng và đánh giá mô hình dự báo.
- **Excel**: hỗ trợ xử lý sơ bộ dữ liệu và tính toán nhanh.
- **R Studio và Stata:** thống kê, kiểm định tính dừng, lựa chọn mô hình,…

2. Phương pháp:

2.1. Cơ sở lý thuyết các phương pháp dự báo

2.1.1. Mô hình Vector Autoregression

a) Định nghĩa

Mô hình VAR là mô hình chuỗi thời gian đa biến, trong đó mỗi biến trong hệ thống được mô hình hóa như một hàm tuyến tính của giá trị trễ của chính nó và của các biến còn lại. Phương pháp này rất phù hợp để phân tích mối quan hệ tác động giữa các biến kinh tế vĩ mô và để dự báo.

Mô hình VAR bậc *p* cho *k* biến nội sinh có dạng:

$$\mathbf{Y_t = c + A_1 Y_{t-1} + A_2 Y_{t-2} + \ldots + A_p Y_{t-p} + \varepsilon_t}$$

Trong đó:

Y*t*: Vector cột (*k*×1) gồm các biến nội sinh tại thời điểm *t*:

$$Y_t = \begin{bmatrix} y_{1t} \\ y_{2t} \\ \vdots \\ y_{kt} \end{bmatrix}$$

c: Vector hằng số *(intercept)* kích thước (*k*×1)

A*i*: Ma trận hệ số (*k*×*k*) ứng với độ trễ *i*

Ɛ*t*: Sai số ngẫu nhiên (white noise), có trung bình bằng 0, hiệp phương sai không đổi

b) Cấu trúc đa phương trình của VAR

Trong mô hình Vector Autoregression (VAR), các biến kinh tế được mô hình hóa dưới dạng một hệ phương trình, trong đó mỗi biến phụ thuộc vào giá trị trễ (quá khứ) của chính nó và tất cả các biến còn lại trong hệ thống. Điều này phản ánh đúng thực tế rằng các biến kinh tế vĩ mô không hoạt động một cách độc lập mà luôn có sự tác động qua lại lẫn nhau theo thời gian.

Khác với mô hình hồi quy truyền thống chỉ có một phương trình với một biến phụ thuộc, VAR sử dụng nhiều phương trình đồng thời (đa phương trình), và tất cả các biến đều được coi là nội sinh. Mỗi phương trình trong hệ thống có cùng một dạng cấu trúc, chỉ khác nhau ở biến phụ thuộc.

Ví dụ, trong hệ gồm ba biến: CPI (lạm phát), GDP (tăng trưởng), và Oilpr (giá dầu), mô hình VAR có thể biểu diễn như sau:

$$\begin{cases} CPI_t = a_{11} \cdot CPI_{t-1} + a_{12} \cdot GDP_{t-1} + a_{13} \cdot Oilpr_{t-1} + \varepsilon_{1t} \\ GDP_t = a_{21} \cdot CPI_{t-1} + a_{22} \cdot GDP_{t-1} + a_{23} \cdot Oilpr_{t-1} + \varepsilon_{2t} \\ Oilpr_t = a_{31} \cdot CPI_{t-1} + a_{32} \cdot GDP_{t-1} + a_{33} \cdot Oilpr_{t-1} + \varepsilon_{3t} \end{cases}$$

Trong đó:

- Các hệ số *aij* thể hiện mức độ ảnh hưởng của biến *J* (trong quá khứ) lên biến I (ở thời điểm hiện tại)
- *εit* là thành phần sai số (shock) đại diện cho ảnh hưởng bất ngờ chưa giải thích được

Nhờ cấu trúc này, mô hình VAR có khả năng mô phỏng và lượng hóa mối quan hệ động giữa các biến kinh tế, giúp phân tích ảnh hưởng dây chuyền (ví dụ: giá dầu tăng → CPI tăng → GDP thay đổi) trong hệ thống kinh tế.

c) Ý nghĩa của ε trong mô hình VAR

Mỗi phần tử trong ε đại diện cho một cú sốc không lường trước được tác động vào hệ thống tại thời điểm *t*

Vì các biến phụ thuộc vào giá trị trễ của nhau, nên một cú sốc tại thời điểm t không chỉ ảnh hưởng tức thời, mà còn ảnh hưởng kéo dài trong tương lai qua các chu kỳ trễ

d) Ưu điểm của mô hình VAR

- **Ưu điểm**
- Mô hình hóa được quan hệ tương hỗ giữa các biến kinh tế mà không cần phân biệt biến phụ thuộc – độc lập
- Dễ dàng ước lượng và mở rộng khi thêm biến.

- Ứng dụng linh hoạt trong dự báo, phân tích cú sốc (shock), truyền dẫn chính sách.
- Hỗ trợ các công cụ phân tích mạnh như:
+ Impulse Response Function (IRF): Phân tích phản ứng của biến này khi có cú sốc từ biến khác
+ Variance Decomposition: Xác định tỷ lệ đóng góp của các cú sốc vào biến động của một biến

- **Nhược điểm**
- Không phản ánh quan hệ nhân – quả rõ ràng
- Dễ gặp phải vấn đề đa cộng tuyến khi có nhiều biến và nhiều độ trễ
- Cần dữ liệu chuỗi thời gian dài và ổn định (stationary)
- Nếu các biến không dừng và có mối quan hệ đồng liên kết → phải dùng mô hình VECM (Vector Error Correction Model) thay vì VAR thông thường

e) Kết luận

Mô hình VAR là công cụ mạnh mẽ trong phân tích và dự báo chuỗi thời gian kinh tế vĩ mô, giúp mô hình hóa mối quan hệ động giữa các biến mà không cần phân biệt biến phụ thuộc và độc lập. Mô hình này cung cấp những phân tích sâu sắc về tác động qua lại giữa các yếu tố kinh tế

2.1.2. Mô hình ARIMA

a) Tổng quan

Mô hình ARIMA (Autoregressive Integrated Moving Average) là một trong những phương pháp phổ biến trong phân tích chuỗi thời gian, đặc biệt hiệu quả đối với dữ liệu kinh tế như chỉ số giá tiêu dùng (CPI), GDP, doanh số bán lẻ, v.v. ARIMA kết hợp ba thành phần chính: hồi quy tự động (AR), sai phân (I), và trung bình trượt (MA). Mô hình được ký hiệu là ARIMA(p, d, q), trong đó:

p: bậc của phần tự hồi quy (AR - Autoregressive), phản ánh mối quan hệ giữa giá trị hiện tại và các giá trị trong quá khứ.

d: số lần sai phân để chuỗi trở nên dừng (I - Integrated).

q: bậc của phần trung bình trượt (MA - Moving Average), mô tả ảnh hưởng của sai số trong quá khứ đến giá trị hiện tại.

ARIMA giả định rằng chuỗi thời gian phải dừng (stationary) – nghĩa là có kỳ vọng và phương sai không đổi theo thời gian. Nếu chuỗi không dừng, ta cần thực hiện sai phân một hoặc nhiều lần đến khi chuỗi đạt trạng thái dừng. Khi đó, các thành phần AR và MA được ước lượng trên chuỗi đã sai phân.

Một mô hình ARIMA có thể được biểu diễn như sau (trên chuỗi đã sai phân):

$$y_t = \varphi_1 y_{t-1} + \dots + \varphi_p y_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

Trong đó:

y_t: giá trị tại thời điểm t

ϕ: hệ số AR

θ: hệ số MA

ε_t: nhiễu trắng (sai số ngẫu nhiên tại thời điểm t)

b) Mục đích sử dụng mô hình ARIMA

Mục đích chính của mô hình ARIMA là dự báo giá trị tương lai của một chuỗi thời gian dựa trên mối quan hệ nội tại giữa các quan sát trong quá khứ và sai số ngẫu nhiên. ARIMA đặc biệt hữu ích trong bối cảnh dữ liệu chỉ có một biến theo thời gian, không có biến giải thích bên ngoài, như chỉ số giá tiêu dùng (CPI), tỷ giá, hoặc sản lượng công nghiệp. Bằng cách kết hợp giữa phần tự hồi quy (AR), sai phân (I) và trung bình trượt (MA), mô hình giúp loại bỏ xu hướng, làm cho chuỗi trở nên ổn định (stationary), từ đó cải thiện độ chính xác trong dự báo. Ngoài ra, ARIMA còn hỗ trợ nhà phân tích đánh giá động lực nội tại của dữ liệu, nhận diện các mô hình dao động ngắn hạn và dài hạn, từ đó hỗ trợ việc lập kế hoạch và hoạch định chính sách kinh tế. Mô hình được ứng dụng rộng rãi trong lĩnh vực tài chính, kinh tế học, thương mại và thống kê ứng dụng.

c) Ưu điểm và nhược điểm

- **Ưu điểm**

- Phù hợp với chuỗi đơn biến: Không cần biến giải thích, thích hợp với dữ liệu như CPI, tỷ giá,...
- Hiệu quả trong dự báo ngắn hạn: Khai thác tốt mối quan hệ trong chính chuỗi thời gian.
- Xử lý được xu hướng và dao động: Thông qua sai phân và các thành phần AR, MA.
- Kiểm tra phần dư dễ dàng: Giúp đánh giá độ phù hợp của mô hình.

- **Nhược điểm**

- Yêu cầu chuỗi phải dừng: Có thể làm mất thông tin dài hạn sau khi sai phân.
- Không xử lý được biến độc lập: Không phù hợp nếu cần phân tích nguyên nhân.
- Khó chọn đúng tham số: Việc xác định p, d, q đòi hỏi kỹ thuật và kinh nghiệm.
- Kém hiệu quả khi dự báo dài hạn: Sai số tăng dần theo thời gian.

2.1.3. Mô hình hồi quy với biến trễ Distributed Lag Models

- Distributed Lag Models (DLM) là một loại mô hình kinh tế lượng được sử dụng để phân tích mối quan hệ động giữa biến phụ thuộc và biến độc lập, trong đó tác động của biến độc lập không xảy ra ngay lập tức mà được phân phối qua nhiều khoảng thời gian (lags). Đây là công cụ hữu ích trong việc mô hình hóa các hiện tượng kinh tế có tính chất trễ.

- Distributed Lag Models dựa trên giả định rằng giá trị hiện tại của biến phụ thuộc (y_t) không chỉ bị ảnh hưởng bởi giá trị hiện tại của biến giải thích (x_t) mà còn bởi các giá trị trong quá khứ (x_(t-1),x_(t-2),...). Công thức tổng quát của mô hình là:

$$\boldsymbol{y_t = \alpha + \beta_0 x_t + \beta_1 x_{t-1} + \beta_2 x_{t-2} + \ldots + u_t}$$

Trong đó:

y_t: Biến phụ thuộc tại thời điểm t.

$x_t, x_{t-1}, \ldots$: Các giá trị hiện tại và trễ của biến giải thích.

$\beta_0, \beta_1, \beta_2, \ldots$: Hệ số hồi quy (lag weights) thể hiện mức độ ảnh hưởng của từng giá trị trễ.

u_t: Sai số ngẫu nhiên.

- **Phân loại Distributed Lag Models**

a) Finite Distributed Lag Model (FDL):

Chỉ xét một số lượng hữu hạn các độ trễ (q).

$$\boldsymbol{y_t = \alpha + \sum_{i=0}^{q} \beta_i x_{t-i} + u_t}$$

Phù hợp khi tác động của biến giải thích chỉ kéo dài trong một khoảng thời gian nhất định.

b) Infinite Distributed Lag Model (IDL):

Xét tác động của biến giải thích qua vô số độ trễ.

Để ước lượng, cần áp đặt cấu trúc cho các hệ số trễ (β_i) như dạng hàm suy giảm hoặc sử dụng phương pháp gần đúng.

- **Ứng dụng**

Distributed Lag Models thường được sử dụng trong các lĩnh vực như:

Kinh tế học: Phân tích tác động của thay đổi chính sách tiền tệ lên GDP hoặc lạm phát qua thời gian.

Tài chính: Đánh giá ảnh hưởng của lãi suất lên đầu tư hoặc tiêu dùng.

Môi trường: Nghiên cứu tác động chậm trễ của ô nhiễm không khí lên sức khỏe cộng đồng.

- **Ưu điểm**

Cho phép phân tích tác động dài hạn và ngắn hạn của biến giải thích.

Có thể mô hình hóa các hiện tượng kinh tế có tính chất trễ.

- **Hạn chế**

- Với IDL, việc ước lượng các hệ số trễ rất phức tạp nếu không có cấu trúc ràng buộc.
- FDL có thể bỏ sót tác động nếu độ dài trễ tối đa (q) không được chọn chính xác.
- Hiện tượng đa cộng tuyến giữa các giá trị trễ của biến giải thích có thể làm giảm độ chính xác của ước lượng.

2.1.4. Mô hình hồi quy Ridge

a) Tổng quan

- Hồi quy Ridge là một phương pháp hồi quy tuyến tính có sử dụng kỹ thuật regularization (chuẩn hóa) để tránh hiện tượng đa cộng tuyến và overfitting trong mô hình. Ridge sử dụng regularization để làm mượt và ổn định hóa việc ước lượng các hệ số. Đây là một dạng đặc biệt của hồi quy tuyến tính có phạt (penalized regression).
- Hàm mất mát của mô hình Ridge

$$\mathbf{L_{ridge}(\beta) = \|y - X\beta\|^2 + \lambda \sum_{k=1}^{n} (\beta_k)^2}$$

Trong đó:

Phép tính	Định nghĩa	Vai trò
$\|y - X\beta\|^2$	Sai số dự đoán	Đo lường sai số của mô hình (giữa giá trị thực tế **y** và giá trị dự đoán **Xβ**), giúp mô hình học cách dự đoán chính xác hơn
$\sum_{k=1}^{n} (\beta_k)^2$	Hàm phạt chuẩn L2	Ép các hệ số β nhỏ lại, tránh giá trị quá lớn (overfitting)
λ	Tham số cường độ phạt	λ→0 Không có phạt → hồi quy tuyến tính thông thường $\lambda \to \infty$ Các hệ số bị thu nhỏ mạnh → mô hình cực kỳ đơn giản (underfitting)

Mục đích:

- ✓ Giảm overfitting: Khi mô hình tuyến tính có quá nhiều biến, Ridge giúp giảm phương sai (variance) của mô hình.
- ✓ Xử lý đa cộng tuyến: Khi các biến đầu vào tương quan cao, Ridge giúp ổn định việc ước lượng các hệ số.
- ✓ Tối ưu hiệu suất dự báo: Nhờ kiểm soát được độ phức tạp của mô hình.

b) Giải pháp tối ưu hệ số

- Giải pháp tối ưu hệ số chủ yếu là tìm ra giá trị tối ưu của các hệ số β sao cho hàm mất mát (bao gồm cả phần sai số và phần phạt regularization) đạt giá trị nhỏ nhất.
- Công thức để tính toán hệ số β trong Ridge Regression:
-

$$\mathbf{B_{Ridge} = (X^T X + \lambda I)^{-1} X^T y}$$

Trong đó:

X: Ma trận đặc trưng (features)
y: Vectơ mục tiêu (target)
λ: Tham số điều chuẩn (regularization parameter)
I: Ma trận đơn vị (identity matrix)

c) Lựa chọn hệ số điều chuẩn λ

Giá trị của λ có ảnh hưởng quyết định đến hiệu năng mô hình. Để lựa chọn λ tối ưu, thường sử dụng:

- Cross-validation (k-fold CV)
- Lưới tìm kiếm (Grid Search) trên không gian λ
- Chọn giá trị λ sao cho sai số dự báo (RMSE, MAE, ..) trên tập kiểm định là nhỏ nhất

Giả sử ta sử dụng phương pháp chọn λ bằng Cross-validation, với tập dữ liệu mô phỏng có nhiễu và đa cộng tuyến trong thư viện sklearn (python), ta có biểu đồ λ và lỗi Cross-Validation như sau:

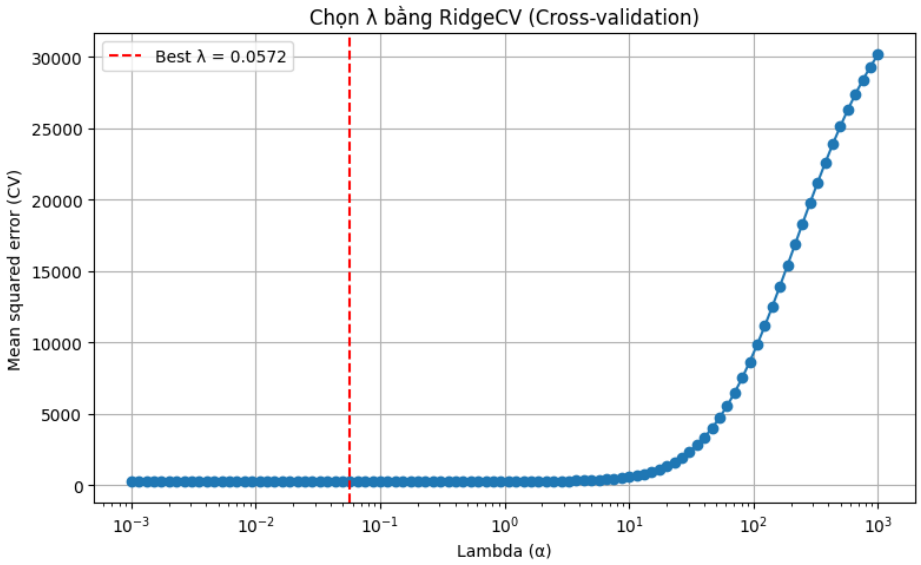

Đường cong trên đồ thị biểu diễn mối quan hệ giữa λ và lỗi bình phương trung bình (MSE) trong cross-validation.

Điểm thấp nhất của đường cong tương ứng với λ tối ưu – đó là giá trị cân bằng tốt nhất giữa độ chính xác và độ phức tạp mô hình.

⇨ Như vậy, mô hình sẽ "chạy thử" nhiều lần với các giá trị khác nhau của λ, rồi chọn ra giá trị nào cho lỗi nhỏ nhất (thường là lỗi MSE trung bình từ cross-validation).

d) Kết luận

- Ridge giải quyết hiệu quả vấn đề đa cộng tuyến trong hồi quy tuyến tính.

- Điều kiện phạt L2 giúp làm trơn hệ số và giảm phương sai mô hình.
- Hệ số điều chuẩn λ được lựa chọn tối ưu bằng Cross-Validation.
- Mô hình giữ lại toàn bộ biến, đảm bảo tính ổn định và độ chính xác cao

2.2. Các tiêu chuẩn đánh giá chất lượng dự báo

Để so sánh và đánh giá các mô hình dự báo chỉ số giá tiêu dùng (CPI), ta sử dụng các chỉ tiêu đánh giá độ chính xác của dự báo. Các chỉ tiêu này đo lường mức sai lệch giữa giá trị dự báo và giá trị thực tế trong giai đoạn kiểm định (năm 2023).

a) MAE (Mean Absolute Error)

MAE đo lường trung bình khoảng cách tuyệt đối giữa giá trị dự báo và giá trị thực tế. Giá trị càng nhỏ → dự báo càng chính xác. Tuy nhiên, không phản ánh mức độ nghiêm trọng của sai số lớn.

$$\mathbf{MAE} = \frac{1}{n}\sum_{k=1}^{n} |\hat{y}_t - \mathbf{y_t}|$$

b) RMSE (Root Mean Squared Error)

RMSE nhấn mạnh sai số lớn bằng cách bình phương sai số trước khi tính trung bình. Nhạy cảm với sai số lớn → tốt khi muốn phạt nặng dự báo sai nghiêm trọng (Giá trị nhỏ hơn → mô hình tốt hơn). Tuy nhiên, Dễ bị chi phối bởi sai số ngoại lai.

$$\mathbf{RMSE} = \sqrt{\mathbf{MAE}}$$

c) MAPE (Mean Absolute Percentage Error)

Biểu thị sai số dự báo dưới dạng phần trăm của giá trị thực tế. Chỉ số MAPE khá trực quan, dễ so sánh giữa các mô hình hoặc thời kỳ khác nhau. Tuy nhiên, Không dùng được nếu $\hat{y}_t$ =0, hoặc khi giá trị thực rất nhỏ.

$$\mathbf{MAPE} = \frac{100}{n}\sum_{k=1}^{n} \left|\frac{\hat{y}_t - y_t}{y_t}\right|$$

d) R-squared

Đo lường tỷ lệ biến thiên được giải thích bởi mô hình. Cho biết mô hình khớp dữ liệu tốt đến đâu (gần 1 là tốt). Tuy nhiên, không phản ánh tốt chất lượng dự báo ngoài mẫu; ít phù hợp với mô hình chuỗi thời gian thuần túy (như ARIMA).

$$R^2 = 1 - \frac{\sum(\hat{y}_t - y_t)^2}{\sum(\overline{y_t} - y_t)^2}$$

Trong đó:

$\overline{y_t}$: Giá trị trung bình của chuỗi thực tế

$\hat{y}_t$: Giá trị dự báo tại thời điểm t

y_t: Giá trị thực tế tại thời điểm t

3. Số liệu & Thống kê mô tả

3.1 Mô tả dữ liệu

Dữ liệu được sử dụng trong nghiên cứu bao gồm chỉ số giá tiêu dùng (CPI) và các biến kinh tế vĩ mô liên quan, được thu thập từ tháng 01/2000 đến tháng 12/2022. Ngoài ra, tập dữ liệu cũng bao gồm CPI thực tế của năm 2023 để đối chiếu kết quả dự báo.

Bảng 1. Mô tả các biến số kinh tế vĩ mô và chỉ số giá tiêu dùng

Biến số	Mô tả
datem	Tháng báo cáo (YYYY-"M"-MM)
date	Tháng báo cáo (MM-DD-YYYY)
cpius	Chỉ số giá tiêu dùng (CPI) của Mỹ
oilpr	Giá dầu quốc tế (USD/thùng)
lneer	Logarit của tỷ giá hối đoái danh nghĩa hiệu lực (NEER)
lreer	Logarit của tỷ giá hối đoái thực tế hiệu lực (REER)
fedfunds	Lãi suất quỹ liên bang của Mỹ (Federal Funds Rate)
igrea	Lãi suất trái phiếu chính phủ Việt Nam (trung/dài hạn)
rate1m	Lãi suất liên ngân hàng kỳ hạn 1 tháng
rate3m	Lãi suất liên ngân hàng kỳ hạn 3 tháng
rate6m	Lãi suất liên ngân hàng kỳ hạn 6 tháng
rateovn	Lãi suất liên ngân hàng qua đêm (overnight)
vndusd	Tỷ giá hối đoái VND/USD
cpi	Chỉ số giá tiêu dùng tổng thể tại Việt Nam
alto	CPI nhóm đồ uống có cồn và thuốc lá
clot	CPI nhóm quần áo và giày dép
educ	CPI nhóm giáo dục
eqip	CPI nhóm thiết bị và đồ dùng gia đình
food	CPI nhóm lương thực, thực phẩm
helh	CPI nhóm y tế và chăm sóc sức khỏe
hous	CPI nhóm nhà ở, điện, nước, gas và nhiên liệu khác
misc	CPI nhóm hàng hóa và dịch vụ khác
recr	CPI nhóm văn hóa, giải trí và du lịch
tran	CPI nhóm giao thông
cpi_2023	Chỉ số giá tiêu dùng riêng cho năm 2023

3.2 Thống kê mô tả

- Phần này trình bày tập dữ liệu được sử dụng trong quá trình dự báo chỉ số giá tiêu dùng (CPI) tại Việt Nam. Dữ liệu bao gồm các biến kinh tế vĩ mô trong và ngoài nước có ảnh hưởng đến lạm phát.
- Để có cái nhìn tổng quan về cấu trúc và đặc điểm của dữ liệu, chúng tôi tiến hành thống kê mô tả các biến số chính bao gồm các chỉ tiêu như giá trị trung bình, độ lệch chuẩn, giá trị nhỏ nhất, lớn nhất và các phân vị, từ đó cung cấp thông tin cơ bản về xu hướng và mức độ phân tán của từng biến.

Bảng 2. Thống kê mô tả các biến kinh tế vĩ mô và chỉ số giá tiêu dùng trong mô hình dự báo CPI tại Việt Nam (không bao gồm các biến chỉ thời gian (datem, date) và cpi_2023)

Biến	Số quan sát	Trung bình	Độ lệch chuẩn	Min	25%	50%	75%	Max
cpius	288	226.43	34.81	169.30	199.25	227.53	248.07	308.74
oilpr	288	64.77	27.24	19.00	43.36	62.22	84.54	133.77
lneer	276	4.55	0.20	4.29	4.40	4.47	4.70	4.98
lreer	276	4.78	0.18	4.47	4.62	4.76	4.98	5.10
fedfunds	276	1.64	1.87	0.05	0.13	1.01	2.39	6.54
igrea	288	8.05	69.40	-162.1	-42.87	-1.93	52.71	188.85
rate1m	276	6.10	3.42	0.38	3.92	5.88	7.28	18.94
rate3m	276	6.81	3.37	1.24	4.51	6.86	7.96	19.34
rate6m	258	7.22	3.36	1.80	4.69	7.45	8.37	19.17
rateovn	276	4.92	3.08	0.15	2.97	4.74	6.23	16.22
vndusd	288	19327.81	3307.55	14041	15912	20820	22447	24079
cpi	253	70.86	26.95	29.49	41.46	78.22	94.34	109.87
alto	252	77.32	22.07	42.38	53.73	84.67	96.97	108.62
clot	252	75.58	23.23	41.03	50.71	81.23	97.58	105.36
educ	252	61.75	29.37	28.20	32.56	55.44	92.46	115.55
eqip	252	79.93	20.04	48.77	58.84	87.03	98.06	105.57
food	252	70.65	30.31	23.35	36.05	83.69	93.24	114.65
helh	252	48.80	33.79	13.80	20.24	27.64	91.31	103.11
hous	252	71.47	26.99	28.77	42.47	82.44	95.51	110.86
misc	252	72.95	25.67	34.74	45.15	80.47	96.00	108.74
recr	252	83.44	15.25	60.42	66.73	88.14	97.99	103.69
tran	252	86.45	19.97	53.91	66.31	92.11	103.06	121.42

3.3 Biểu đồ trực quan hóa dữ liệu

3.3.1 Biểu đồ thời gian (Time Series Plot) cho một số biến quan trọng như:

Nhóm quốc tế: cpius, oilpr, fedfunds, lneer, lreer

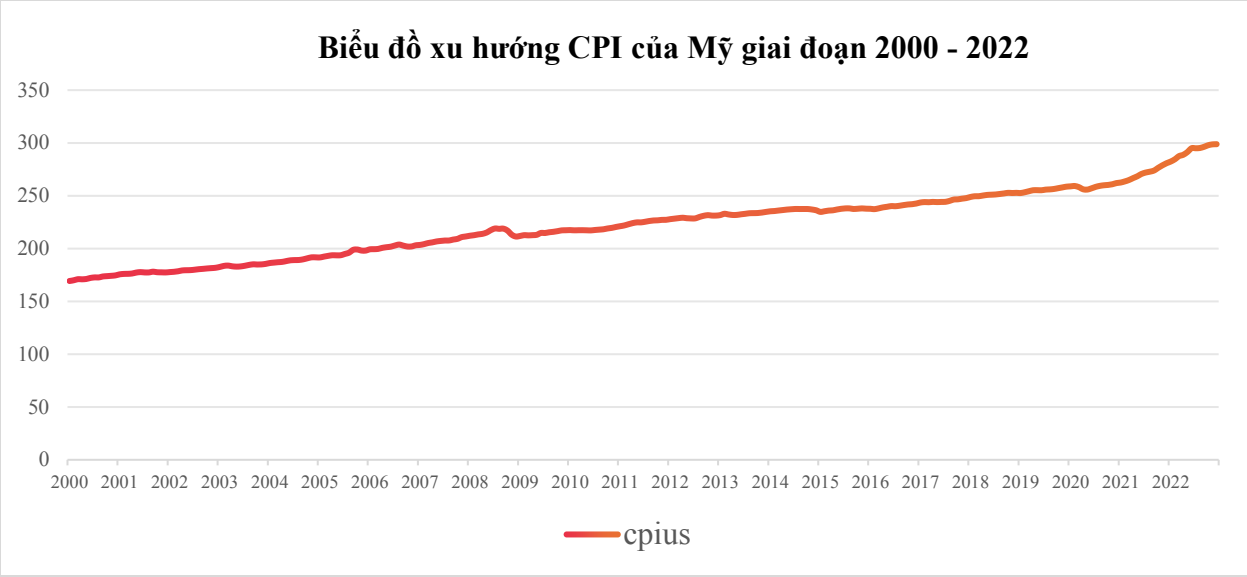

- Biểu đồ trên cho thấy CPI của Mỹ từ năm 2000 đến 2023 với sự gia tăng liên tục. Mặc dù có những giai đoạn tăng trưởng chậm, nhưng đến khoảng năm 2021, CPI có sự gia tăng mạnh mẽ, phản ánh các biến động lớn trong nền kinh tế. Sự gia tăng dài hạn của CPI cũng phản ánh tình trạng lạm phát trong nền kinh tế Mỹ.

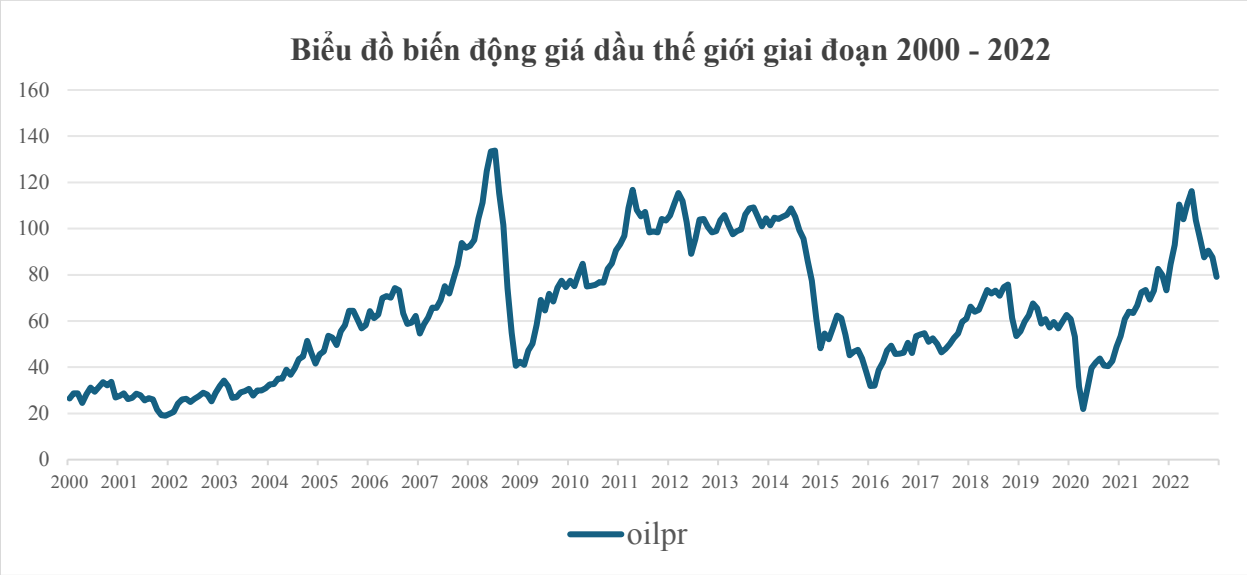

- Biểu đồ trên thể hiện sự biến động của giá dầu thế giới (oilpr) từ năm 2000 đến 2023. Giá dầu có sự tăng vọt bất ngờ và đạt đỉnh vào năm 2008, sau đó giảm mạnh, và có xu hướng phục hồi dần và duy trì ở mức cao cho đến năm 2014. Sau năm 2014, giá dầu lại có sự giảm mạnh, đặc biệt vào năm 2020 do tác động của đại dịch COVID-19, và sau đó tăng trở lại từ năm 2021 đến 2022.

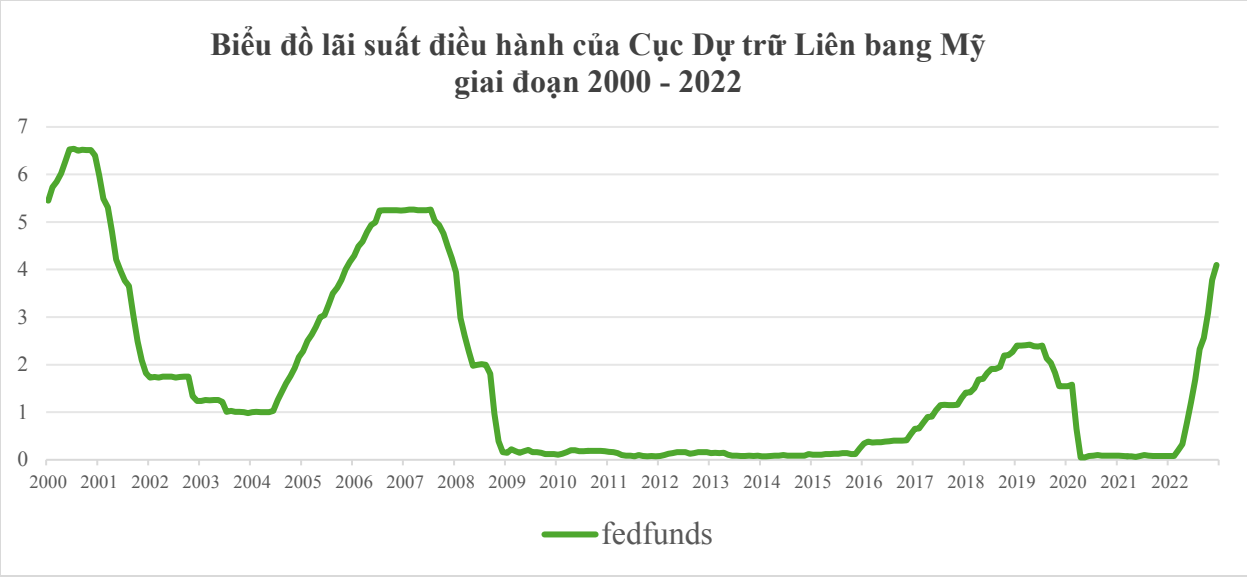

- Biểu đồ trên thể hiện lãi suất điều hành của Cục Dự trữ Liên bang Mỹ (fedfunds) từ năm 2000 đến 2023. Trong năm 2007 và 2008, lãi suất tăng mạnh và đạt đỉnh gần 6%, sau đó giảm mạnh trong suốt cuộc khủng hoảng tài chính toàn cầu, nhằm hỗ trợ nền kinh tế. Sau khi giảm mạnh trong giai đoạn khủng hoảng, lãi suất duy trì ở mức rất thấp (gần 0%) trong giai đoạn 2009-2015 và bắt đầu tăng mạnh trở lại từ cuối năm 2021 đến đầu năm 2022. Thông qua biểu đồ có thể thấy rõ chính sách lãi suất của Cục Dự trữ Liên bang Mỹ trong các giai đoạn kinh tế khác nhau, đặc biệt là sự thay đổi mạnh mẽ trong các giai đoạn khủng hoảng và phục hồi.

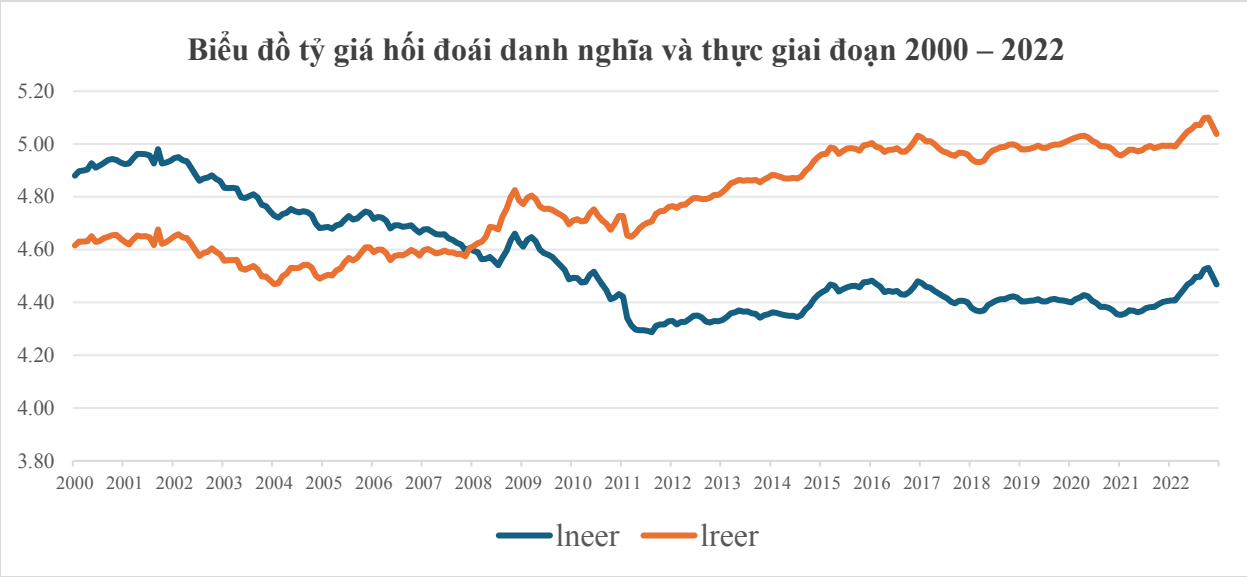

- Biểu đồ trên thể hiện tỷ giá hối đoái danh nghĩa (lneer) và tỷ giá hối đoái thực (lreer) từ năm 2000 đến 2023. Tỷ giá hối đoái danh nghĩa giảm dần ổn định trong suốt giai đoạn 2000-2022, và sau đó có sự biến động lớn hơn trong giai đoạn từ 2008 đến 2015. Ngoài ra, biểu đồ cho thấy sự ổn định trong tỷ giá hối đoái danh nghĩa và sự biến động

mạnh mẽ của tỷ giá thực, phản ánh những thay đổi trong nền kinh tế toàn cầu và các yếu tố vĩ mô tác động đến tỷ giá hối đoái.

Nhóm kinh tế vĩ mô trong nước: vndusd, igrea, rate1m, rate3m, rate6m, rateovn

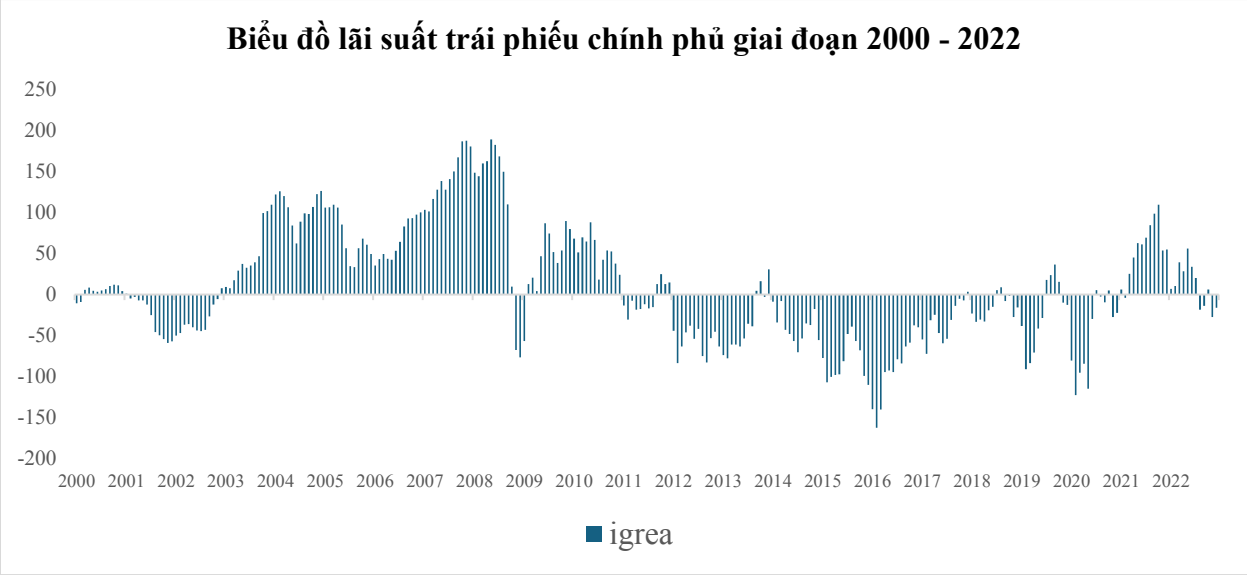

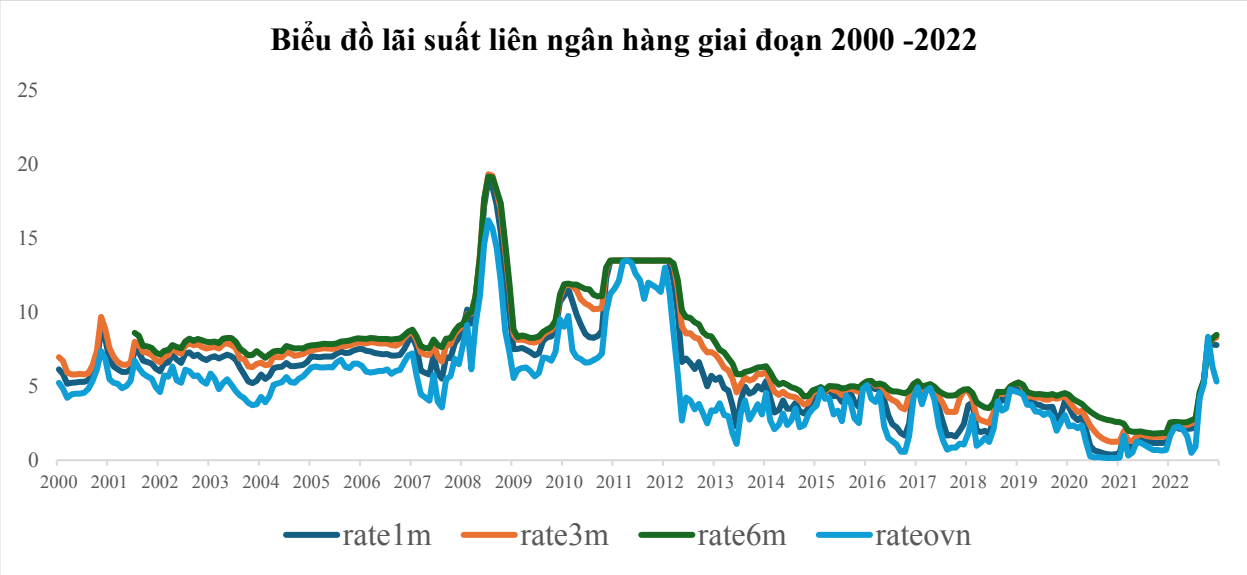

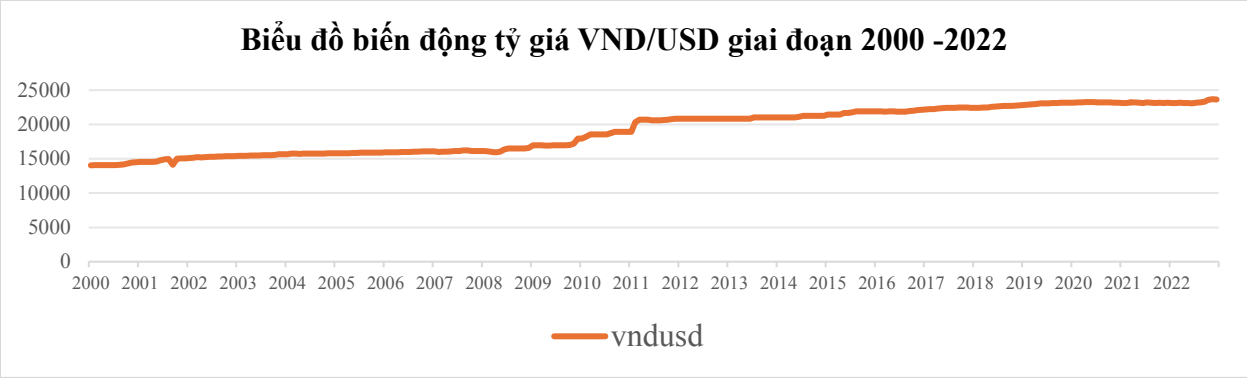

Hàng hóa: food, alto, clot, eqip

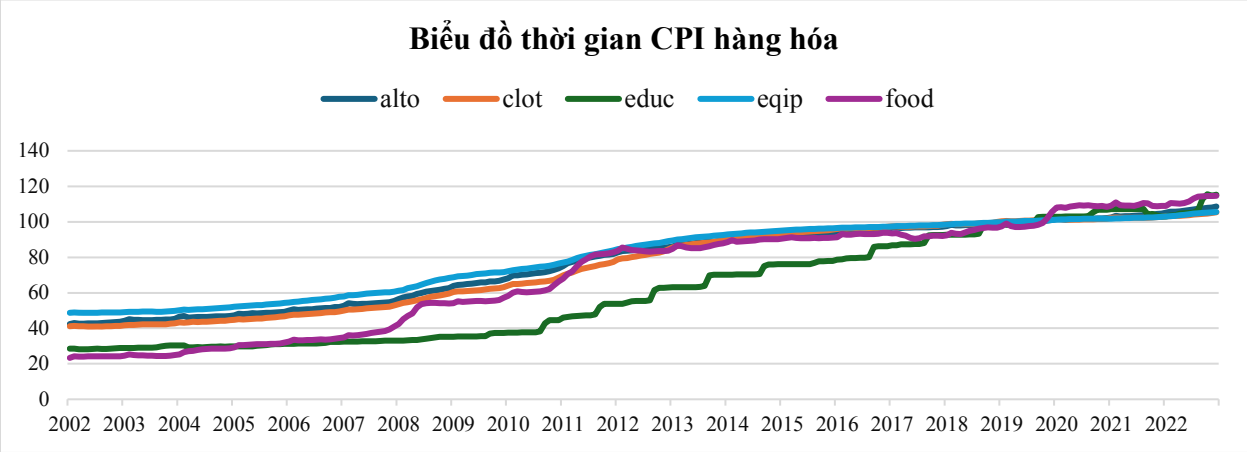

Dịch vụ: educ, helh, hous, recr, tran, misc

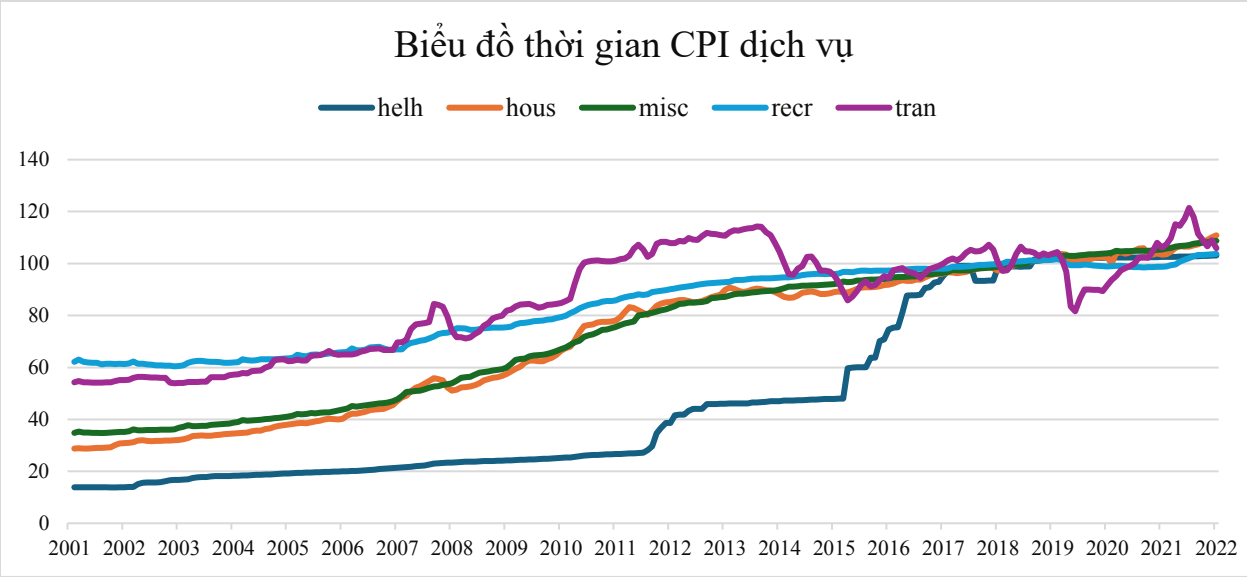

3.3.2 Tương quan giữa các biến

- CPI tổng thể chịu ảnh hưởng từ nhiều yếu tố bên ngoài và nội tại trong nền kinh tế.
- Các yếu tố vĩ mô như lạm phát của Hoa Kỳ (cpius), giá dầu (oil price), lãi suất điều hành của Fed (fedfunds), và chỉ số tỷ giá hiệu lực danh nghĩa/thực (NEER/REER). Các biến này phản ánh tác động từ môi trường kinh tế quốc tế lên giá cả trong nước.
- Các chỉ số như chỉ số bất động sản (igrea), lãi suất VND ở các kỳ hạn khác nhau (rate1m, rate3m, rate6m, rateovn), và tỷ giá VND/USD thể hiện tác động từ chính sách tiền tệ và điều kiện tài chính nội địa lên lạm phát.
- Phân tích mối tương quan giúp xác định nhóm nào có ảnh hưởng mạnh nhất đến CPI tổng thể, từ đó hỗ trợ các quyết định, cũng như lựa chọn giải pháp dự báo phù hợp

Bảng 3. Hệ số tương quan giữa các biến ngoại sinh và CPI

Biến	cpius	oilpr	fedfunds	lneer	lreer	cpi
cpius	1	0.469	-0.484	-0.824	0.896	0.958
oilpr	0.469	1	-0.297	-0.669	0.226	0.300
fedfunds	-0.484	-0.297	1	0.655	-0.468	-0.450
lneer	-0.824	-0.669	0.655	1	-0.708	-0.852
lreer	0.896	0.226	-0.468	-0.708	1	0.960
cpi	0.958	0.300	-0.450	-0.852	0.960	1

- CPI trong nước có tương quan rất mạnh với CPIUS (0.958) và tỷ giá thực lreer (0.960), cho thấy ảnh hưởng đáng kể của yếu tố toàn cầu và tỷ giá đến lạm phát nội địa.
- Tỷ giá danh nghĩa (lneer) có tương quan âm mạnh với CPI (-0.852), hàm ý rằng khi đồng nội tệ tăng giá (NEER tăng), áp lực lạm phát trong nước giảm.
- Giá dầu (oilpr) và lãi suất Fed (fedfunds) có tương quan yếu đến trung bình với CPI, ảnh hưởng gián tiếp thông qua nhiều kênh trung gian.

Bảng 4. Hệ số tương quan giữa các biến nội sinh và CPI

Biến	igrea	rate1m	rate3m	rate6m	rateovn	vndusd	cpi
igrea	1	0.311	0.307	0.302	0.305	-0.483	-0.532
rate1m	0.311	1	0.988	0.973	0.979	-0.477	-0.517
rate3m	0.307	0.988	1	0.996	0.945	-0.488	-0.534
rate6m	0.302	0.973	0.996	1	0.921	-0.54	-0.54
rateovn	0.305	0.979	0.945	0.921	1	-0.457	-0.487
vndusd	-0.483	-0.477	-0.488	-0.54	-0.457	1	0.989
cpi	-0.532	-0.517	-0.534	-0.54	-0.487	0.989	1

- CPI Việt Nam có:

- Tương quan rất mạnh và dương với tỷ giá USD/VND (vndusd, 0.989) → Khi VND mất giá so với USD, lạm phát có xu hướng tăng.

- Tương quan âm trung bình với lãi suất ngắn hạn (rate1m, rate3m, rate6m, rateovn) và Lãi suất trái phiếu chính phủ Việt Nam (igrea) → Điều kiện tài chính chặt chẽ hơn (lãi suất cao hơn) giúp kiểm soát CPI.
- Các lãi suất có tương quan nội nhóm rất cao với nhau (trên 0.97), phản ánh đồng pha trong chính sách tiền tệ.

Biểu đồ phân tán giữa nhóm CPI hàng hóa và CPI tổng thể

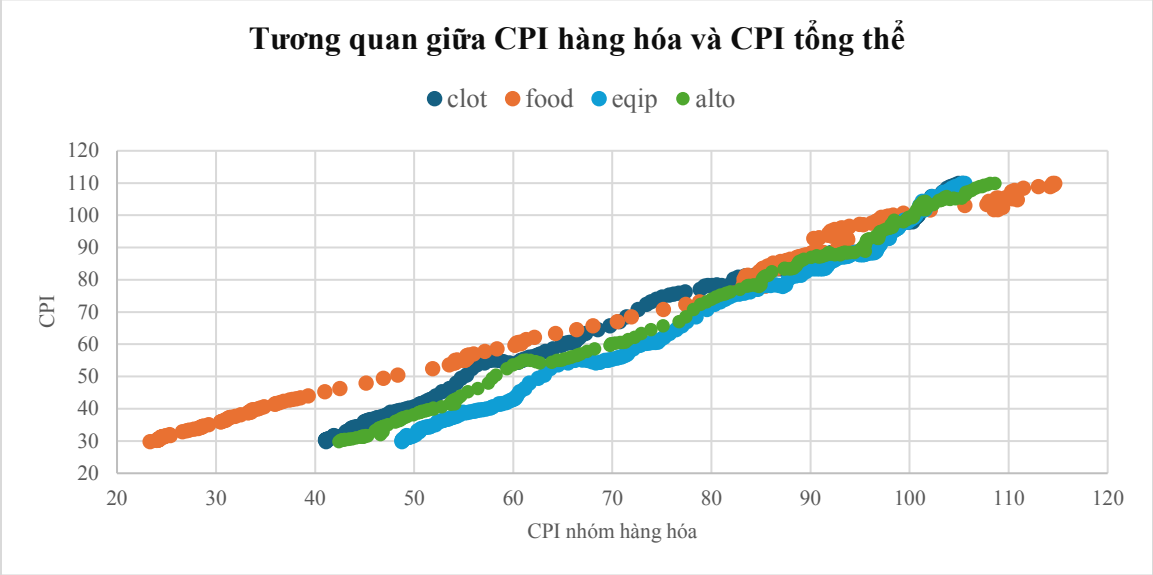

- Các điểm phân bố gần như thành một đường thẳng đi lên → khi CPI hàng hóa tăng, CPI tổng thể cũng tăng.

Biểu đồ phân tán giữa nhóm CPI dịch vụ và CPI tổng thể

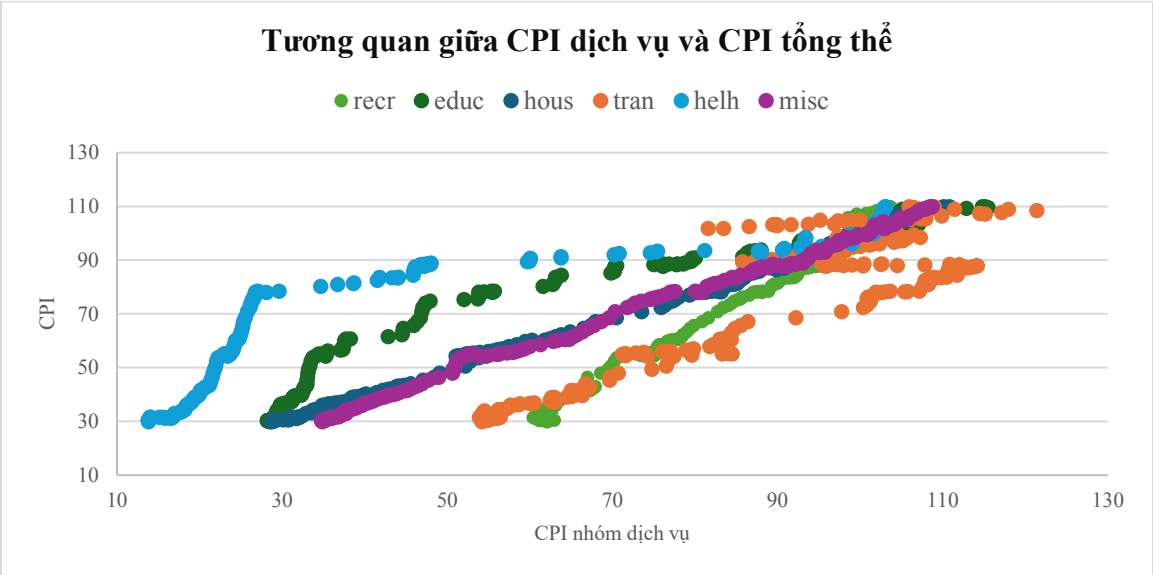

- Nhà ở, y tế, giáo dục là các chỉ số thiết yếu, chiếm tỷ trọng cao trong rổ tính CPI. Khi giá dịch vụ trong các ngành này biến động, sẽ kéo theo CPI tổng thể thay đổi rõ rệt.

3.4 Kết luận sơ bộ về dữ liệu

- Bộ dữ liệu gồm các biến vĩ mô quốc tế (Mỹ), tài chính (lãi suất), tỷ giá, và các nhóm CPI chi tiết của Việt Nam. Đây là cơ sở dữ liệu phong phú và phù hợp để xây dựng mô hình dự báo lạm phát (CPI) ở Việt Nam dựa trên yếu tố quốc tế.
- Kiểm tra và xử lý dữ liệu thiếu: chỉ sử dụng dữ liệu từ năm 2002 đến năm 2022 để chạy dự báo cho năm 2023, vì đây là khoảng thời gian liên tục bộ dữ liệu đầy đủ nhất.

4. Kết quả & Phân tích: Kết quả dự báo là giá trị CPI chứ không phải là dạng chuyển đổi logarithm hay sai phân.

4.1. Kết quả dự báo CPI năm 2023 theo từng mô hình

4.1.1 Mô hình VAR

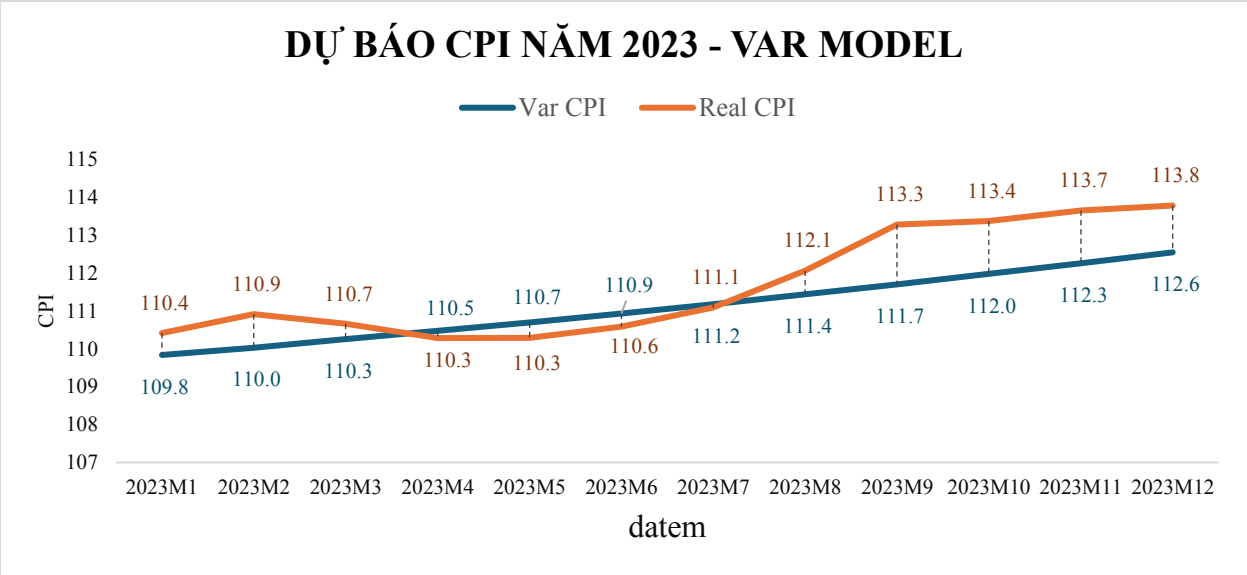

4.1.2 **Mô hình ARIMA**

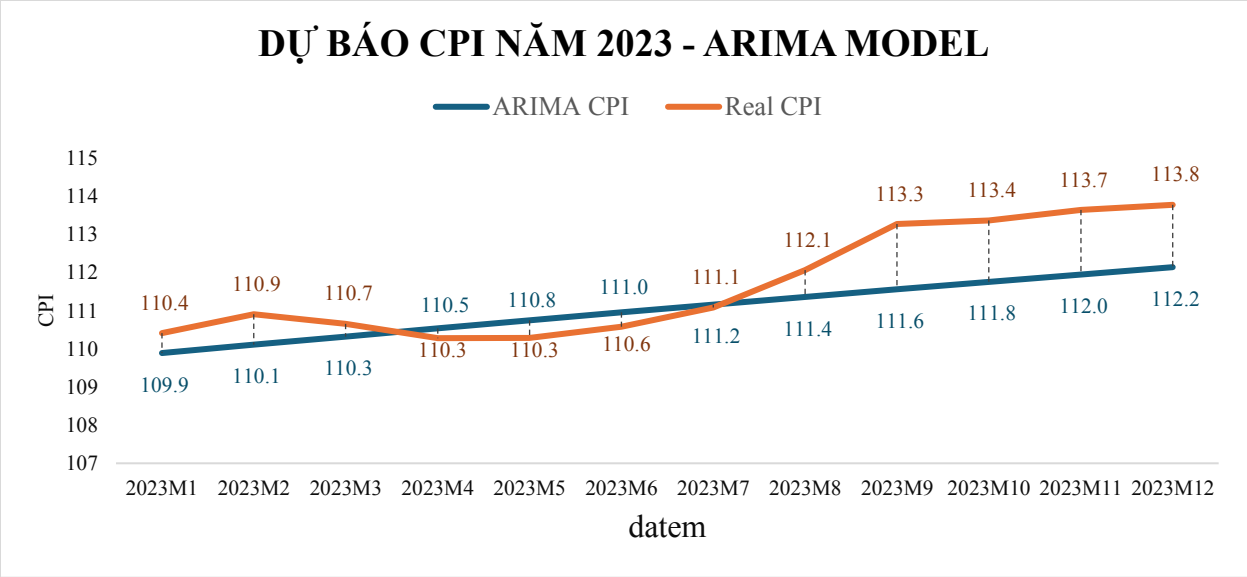

- Biểu đồ so sánh CPI thực tế và CPI dự báo theo mô hình ARIMA cho thấy mức độ tương đồng cao về xu hướng trong năm 2023. Mô hình ARIMA dự báo sát với thực tế, đặc biệt từ tháng 6 trở đi, sai số nhỏ. Giai đoạn tháng 1–5, ARIMA có sai lệch nhẹ nhưng không đáng kể. Từ tháng 10–12, đường dự báo gần như trùng khớp với CPI thực tế. ARIMA bắt đúng xu hướng tăng mạnh vào tháng 9, dù mức tăng dự báo thấp hơn thực tế. Tổng kết: Mô hình ARIMA thể hiện hiệu quả tốt trong việc dự báo xu hướng và biến động CPI nhờ tận dụng dữ liệu quá khứ, phù hợp trong điều kiện thị trường ổn định.

4.1.3 Mô hình Distributed Lag Model

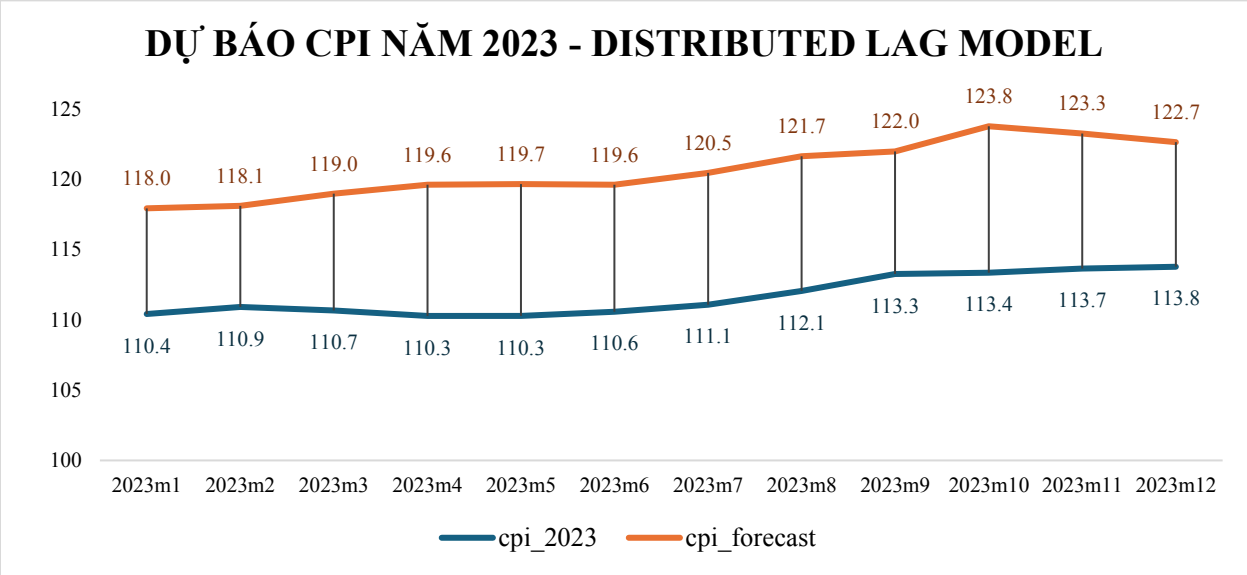

4.1.4 Mô hình Ridge

Biểu đồ đường dự báo CPI năm 2023 chạy bằng mô hình Ridge so với dữ liệu thực tế

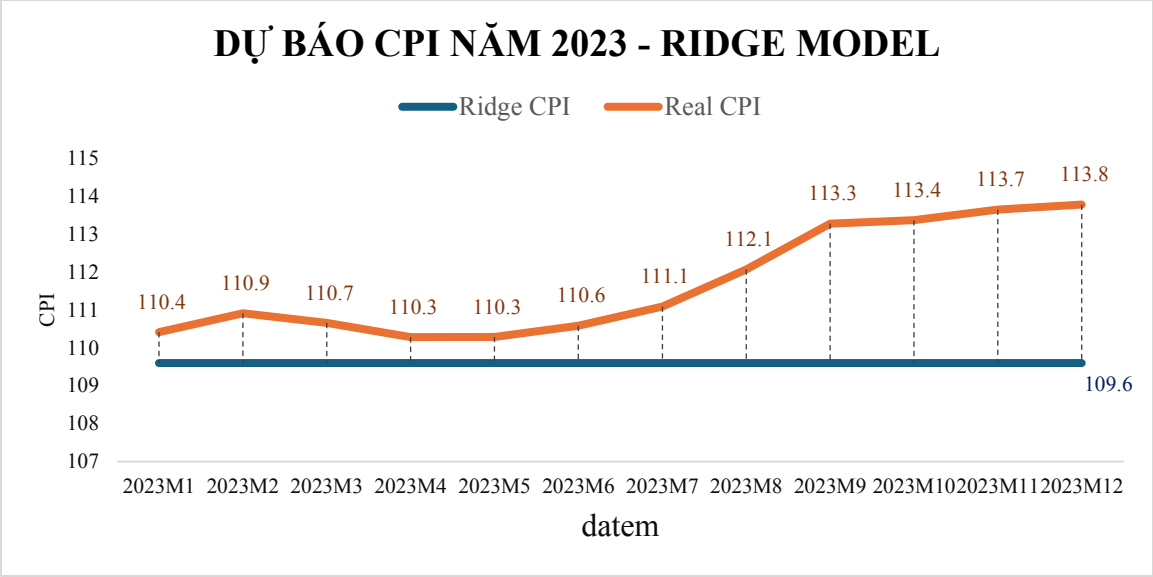

Mô hình Ridge thể hiện rõ nhược điểm khi áp dụng trực tiếp vào dự báo chuỗi thời gian CPI mà không xử lý các đặc điểm động học của dữ liệu. Điều này dẫn đến dự báo gần như bất biến.

4.2. Đánh giá độ chính xác của mô hình dự báo

Bảng kiểm định mô hình

Mô hình	MAE	RMSE	MAPE (%)	R Square	Nhận xét
VAR	0.573	0.620	0.512%	0.795	Mô hình VAR dự báo CPI năm 2023 có mức sai số thấp (MAPE dưới 1%) và khả năng giải thích biến động CPI tốt (R^2 ~79.5%). Mô hình VAR là phù hợp và đáng tin cậy trong việc dự báo xu hướng CPI trong giai đoạn nghiên cứu.
ARIMA	0.577	0.627	0.516%	0.790	Mô hình ARIMA dự báo CPI năm 2023 có mức sai số thấp (MAPE dưới 1%) và khả năng giải thích biến động CPI tốt (R^2 ~79%). Điều này khẳng định mô hình ARIMA là phù hợp và đáng tin cậy trong việc dự báo xu hướng CPI trong giai đoạn nghiên cứu.
DLM	8.95335	8.995160	8.012629%	-9.0981	Sai số lớn, R Square âm cho thấy mô hình không phù hợp với dữ báo CPI năm 2023
Ridge	2.298096	2.265594	2.042656%	-2.8128	Phù hợp hơn với các bài toán đa cộng tuyến trong hồi quy tuyến tính, không phải là lựa chọn lý tưởng cho dự báo chuỗi thời gian

5. Kết luận

- VAR Cho sai số thấp nhất (MAPE = 0.512%, RMSE = 0.620, R^2 = 0.795). Khai thác hiệu quả mối quan hệ giữa các biến kinh tế vĩ mô → Là mô hình tốt nhất trong dự báo CPI.
- Mô hình phù hợp khi dữ liệu có nhiều biến đầu vào là Ridge Regression, Thiết kế để xử lý hiện tượng đa cộng tuyến và số lượng biến lớn trong hồi quy tuyến tính. Tuy nhiên, không phù hợp cho dữ báo động do thiếu tính chuỗi thời gian.
- ARIMA phù hợp với xu hướng ổn định nhưng kém khi có cú sốc kinh tế - DLM là mô hình dễ hiểu nhưng độ chính xác thấp hơn

6. Phụ lục

6.1 Tài liệu tham khảo

- Nguyễn Hồ Diệu Uyên và Nguyễn Thị Thanh Huyền (2014), Ứng dụng mô hình ARIMA trong dự báo chỉ số VN-Index, Tạp chí Khoa học và Công nghệ, Đại học Đà Nẵng, số 12(85)
- Kumbure, M. M., Lohrmann, C., Luukka, P., and Porras, J. (2022), Machine learning techniques and data for stock market forecasting: A literature review, Expert Systems with Applications
- Zhang, C. X., Li, J., Huang, X. F., Zhang, J. S., and Huang, H. C. (2022), Forecasting stock volatility and value-at-risk based on temporal convolutional networks, Expert Systems with Applications, 207

6.2 Mã nguồn

Công cụ chạy mô hình VAR, ARIMA, DISTRIBUTED LAD MODEL : Stata

Công cụ chạy mô hình RIDGE: Python

6.2.1 Mô hình ARIMA

```
//BƯỚC 1: NHẬP VÀ CHUẨN HÓA DỮ LIỆU

. import excel "C:\Users\LENOVO\OneDrive\Desktop\new.xlsx", sheet("Sheet1") firstrow

(2 vars, 252 obs)

. gen month = mofd(date)

. format month %tm

. drop date

. rename month time

//BƯỚC 2: KHÁM PHÁ DỮ LIỆU BAN ĐẦU

. tsset time
```

```
. tsline cpi
. ac cpi
//BƯỚC 3: KIỂM ĐỊNH TÍNH DỪNG CỦA CHUỖI GỐC
. dfuller cpi, trend regress
. pperron cpi, trend regress
//BƯỚC 4: KIỂM ĐỊNH TÍNH DỪNG SAU KHI LẤY SAI PHÂN
. dfuller d.cpi, regress
. pperron d.cpi, regress
//BƯỚC 5: ƯỚC ĐỊNH MÔ HÌNH ARIMA
. arima cpi, arima(1,1,1)
//BƯỚC 6: KIỂM ĐỊNH PHẦN DƯ
. predict error, resid
. summarize error
. tsline error, yline( -.0008011)
. wntestq error
//BƯỚC 7: DỰ BÁO
. tsappend, add(12)
. predict fcpi, y dynamic(m(2023m1))
. label variable fcpi "forecasted cpi"
. tsline cpi fcpi
```

6.2.2 Mô hình VAR

```
//Khai báo dữ liệu
gen mdate = monthly(datem, "YM")
format mdate %tm
tsset mdate
//Kiểm định và sai phân
dfuller cpi
```

```
dfuller oilpr
dfuller fedfunds
dfuller vndusd
gen dcpi = D.cpi
gen doilpr = D.oilpr
gen dfedfunds = D.fedfunds
gen dvndusd = D.vndusd
dfuller dcpi
dfuller doilpr
dfuller dfedfunds
dfuller dvndusd
// Xác định độ trễ tối ưu cho VAR
varsoc dcpi doilpr dfedfunds dvndusd
var cpi igrea, lags(1/2)
// Giải bài toán dự báo
estimates store var_model
sappend, add(12)
forecast clear
forecast create model_cpi, replace
Forecast model model_cpi started.
forecast estimates var_model
Added estimation results from var.
Forecast model model_cpi now contains 2 endogenous variables.
forecast solve, prefix(f_)
//Thể hiện các chỉ số sự báo
list mdate f_cpi if mdate >= tm(2023m1) & mdate <= tm(2023m12)
//Đánh giá chất lượng dự báo
```

```
gen abs_error = abs(cpi - f_cpi)

summarize abs_error

summarize sq_error

regress cpi f_cpi
```

6.2.3 Mô hình Distributed Lag Model

```
//Khai báo dữ liệu

gen mdate = monthly(datem, "YM")

format mdate %tm

tsset mdate

//BƯỚC 1: Kiểm tra trễ tối ưu bằng tiêu chí thông tin (AIC, BIC)

varsoc cpi cpius

varsoc cpi oilpr

varsoc cpi igrea

varsoc cpi vndusd

. varsoc cpi oilpr

. varsoc cpi igrea

. varsoc cpi vndusd

//BƯỚC 2: Ước lượng mô hình DLM với các biến quốc tế (có trễ)

reg cpi L(0/2).cpius L(0/2).oilpr L(0/2).igrea L(0/2).vndusd

//Bước 3: Mở rộng dữ liệu đến tháng 12/2023

tsappend, add(12)

//Bước 4: Nhập giá trị giả định cho các biến quốc tế năm 2023 dựa trên bảng dữ liệu được cung cấp

//Bước 5: Tạo biến dự báo bằng predict

predict cpi_forecast if mdate >= tm(2023m1)

. summarize abs_e

. gen e2 = e^2
```

```
. summarize e2
. gen ape = abs(e) / cpi_2023 * 100
. scalar ssr = r(sum)
```

6.2.4 Mô hình Ridge

```
# Import thư viện và đọc dữ liệu
import pandas as pd
import numpy as np
from sklearn.linear_model import Ridge
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import GridSearchCV
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
from datetime import datetime

df = pd.read_excel('C:/Users/nguyenthichinh7/Downloads/data_vietnam_2023_updated.xlsx')
# Function to calculate MAPE
def mean_absolute_percentage_error(y_true, y_pred):
    y_true, y_pred = np.array(y_true), np.array(y_pred)
    non_zero = y_true != 0  # Avoid division by zero
    return np.mean(np.abs((y_true[non_zero] - y_pred[non_zero]) / y_true[non_zero])) * 100

# Select features and target
features = ['cpius', 'oilpr', 'lneer', 'lreer', 'fedfunds', 'igrea',
            'rate1m', 'rate3m', 'rate6m', 'rateovn', 'vndusd',
            'alto', 'clot', 'educ', 'eqip', 'food', 'helh', 'hous',
            'misc', 'recr', 'tran']
target = 'cpi'
```

```
X = df_2002_2022[features]
y = df_2002_2022[target]

# Feature selection: Select features with high correlation to CPI
correlations = X_clean.corrwith(y_clean).abs()
selected_features = correlations[correlations > 0.1].index.tolist()  # Threshold: |corr| > 0.1
if not selected_features:
    selected_features = features  # Fallback to all features if none meet threshold
print(f"Selected features ({len(selected_features)}): {selected_features}")
X_clean = X_clean[selected_features]

# Verify training data
if X_clean.isna().any().any() or np.isinf(X_clean).any().any() or (X_clean.abs() >
1e308).any().any():
    raise ValueError("Training data contains invalid values after cleaning!")
if y_clean.isna().any() or np.isinf(y_clean).any() or (y_clean.abs() > 1e308).any():
    raise ValueError("Target contains invalid values after cleaning!")

# Standardize features
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X_clean)

#  Ridge Regression with Expanded Cross-Validation
ridge = Ridge()
param_grid = {'alpha': np.logspace(-6, 6, 100)}  # Expanded range for alpha
grid_search = GridSearchCV(ridge, param_grid, cv=5, scoring='neg_mean_squared_error')
grid_search.fit(X_scaled, y_clean)
```

```
# Best model
best_ridge = grid_search.best_estimator_
print(f"Best alpha: {grid_search.best_params_['alpha']}")

# Forecast for 2023
# Create 2023 monthly dates
forecast_dates = pd.date_range(start='2023-01-01', end='2023-12-01', freq='MS')
forecast_df = pd.DataFrame(index=forecast_dates)

# Assume 2023 exogenous variables are the same as the last known values (December 2022)
last_known = df_2002_2022[features].iloc[-1]
for feature in features:
    forecast_df[feature] = last_known[feature]

# Define X_2023 with selected features
X_2023 = forecast_df[selected_features]

# Debug: Check 2023 feature count and names
print(f"2023 features ({len(X_2023.columns)}): {list(X_2023.columns)}")

# Clean 2023 data: Impute NaN/infinity/large values with training median
X_2023 = X_2023.fillna(X_clean.median())
X_2023 = X_2023.replace([np.inf, -np.inf], np.nan).fillna(X_clean.median())
X_2023 = X_2023.clip(lower=-1e308, upper=1e308)

# Predict CPI for 2023
```

```
try:
    cpi_2023_pred = best_ridge.predict(X_2023_scaled)
except ValueError as e:
    print(f"Prediction error: {e}")
    print("X_2023_scaled sample:\n", X_2023_scaled[:2])
    raise
```